

Carregar dados, medidas separatrizes e de dispersão

MATF14 - Estatística Econômica I

Rodney Fonseca

27/04/2026

Iniciando o R no Colab

R disponível no Google Colab

Welcome To Colab

File Edit View Insert Runtime Tools Help

Q Commands + Code + Text ▶ Run all Copy to Drive

Table of contents

- Welcome to Colab!
- Getting started
- Data science
- Machine learning
- More Resources

Featured examples

+ Section

Welcome to Colab!

Access Popular LLMs via Google-Colab-AI Without an API Key

Users with Colab's paid plans have free access to most popular LLMs via google-colab-ai Python library. For more details, refer to the [getting started with google colab ai](#).

```
from google.colab import ai
response = ai.generate_text("What is the capital of France?")
print(response)
```

Explore the Gemini API

The Gemini API gives you access to Gemini models created by Google DeepMind. Gemini models are built from the ground up to be multimodal, so you can reason seamlessly across text, images, code, and audio.


How to get started?

- Go to [Google AI Studio](#) and log in with your Google account.
- Create an [API key](#).
- Use a quickstart for [Python](#), or call the REST API using [curl](#).


Discover Gemini's advanced capabilities

- Play with Gemini [multimodal outputs](#), mixing text and images in an iterative way.
- Discover the [multimodal Live API](#) (demo [here](#)).


Criando um notebook no Colab




Página de um notebook no Colab



Selecionando a linguagem R no Colab



Selecionando a linguagem R no Colab



Carregar dados no Colab e em R

- ▶ Vimos que planilhas em R são objetos do tipo **dataframes**, que podem armazenar variáveis de diferentes tipos


- ▶ Vimos que planilhas em R são objetos do tipo **dataframes**, que que podem armazenar variáveis de diferentes tipos
- ▶ Nesse material, discutiremos como carregar arquivos .csv (sigla em inglês para *valores separados por vírgula*), que é um dos formatos mais comuns para arquivos de dados
- ▶ Usaremos a função `read.csv()` e os dados poderão ser salvos em uma variável **com algum nome sugestivo**

Carregando a planilha no Colab

- ▶ Vamos fazer o upload da planilha `empresa.csv` disponível no Moodle para o Colab
- ▶ Baixe a planilha no link *Dados de empresas* no Moodle
- ▶ Abra o Colab e clique no ícone de uma pasta na aba do lado esquerdo

Local para upload da planilha

- ▶ Você pode arrastar o arquivo para essa aba ou clicar no botão para upload (página com uma seta para cima)



Lendo planilhas em R

- ▶ Usamos a função `read.csv()` com o nome do arquivo entre aspas. A opção `header=TRUE` indica que a planilha tem um cabeçalho, enquanto `dec=','` indica que casas decimais são separadas por vírgula

```
empresas = read.csv('empresas.csv', header = TRUE,  
                    dec = ',')
```

Lendo planilhas em R

- ▶ Usamos a função `read.csv()` com o nome do arquivo entre aspas. A opção `header=TRUE` indica que a planilha tem um cabeçalho, enquanto `dec=','` indica que casas decimais são separadas por vírgula

```
empresas = read.csv('empresas.csv', header = TRUE,  
                    dec = ',')
```

- ▶ Note que os dados já são lidos como um dataframe

```
class(empresas)
```

```
## [1] "data.frame"
```

Para visualizar a planilha, use a função `View(empresas)`

- ▶ A função `dim()` nos mostra a dimensão dos dados, que contém 106 observações e 11 variáveis

```
dim(empresas)
```

```
## [1] 106  11
```

- ▶ A função `dim()` nos mostra a dimensão dos dados, que contém 106 observações e 11 variáveis

```
dim(empresas)
```

```
## [1] 106  11
```

Nomes das variáveis

```
names(empresas)
```

```
## [1] "Empresa"      "constituicao"  "porte"        "en  
## [5] "faturamento98" "faturamento99" "idade"        "c  
## [9] "atividade"    "setor"        "regiao"
```


Checando os cinco primeiro valores de uma das variáveis

```
empresas$idade[1:5]
```

```
## [1] 15  5 21 12 18
```

Checando os cinco primeiro valores de uma das variáveis

```
empresas$idade[1:5]
```

```
## [1] 15  5 21 12 18
```

Frequências absolutas de uma variável qualitativa

```
table(empresas$constituicao)
```

```
##
```

```
## Individual      Ltda.      S.A.
```

```
##           16           30           60
```

Medidas de posição central para variáveis quantitativas

Calculando a média com a função `mean`

```
mean(empresas$idade)
```

```
## [1] 15.53774
```

Calculando a média com a função `mean`

```
mean(empresas$idade)
```

```
## [1] 15.53774
```

Calculando a mediana com a função `median`

```
median(empresas$idade)
```

```
## [1] 15
```

Calculando a média com a função `mean`

```
mean(empresas$idade)
```

```
## [1] 15.53774
```

Calculando a mediana com a função `median`

```
median(empresas$idade)
```

```
## [1] 15
```


Sumário da variável

```
summary(empresas$idade)
```

##	Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
##	2.00	8.00	15.00	15.54	22.75	42.00

Histograma

```
hist(empresas$idade,  
     main = 'Idade',  
     ylab = 'Frequência', xlab = 'Anos')
```



Quantis em R

Definição de percentil

- ▶ O percentil de ordem $i\%$ é um número P_i tal que $i\%$ dos dados são menores que tal valor
- ▶ Percentis especiais
 - ▶ Primeiro quartil ou Q_1 : percentil 25%
 - ▶ Segundo quartil ou Q_2 : percentil 50% (mediana)
 - ▶ Terceiro quartil ou Q_3 : percentil 75%

Percentis em R

- ▶ Usamos a função `quantile()` para calcular percentis/quartis em R

Percentis em R

- ▶ Usamos a função `quantile()` para calcular percentis/quartis em R

Percentil 50% do tempo de existência das empresas

```
quantile(x = empresas$idade, probs = 0.5)
```

```
## 50%
```

```
## 15
```

Mediana do tempo de existência das empresas


```
median(empresas$idade)
```

```
## [1] 15
```

Quartis do tempo de existência das empresas

```
Q1 = quantile(empresas$idade, 0.25)
Q2 = quantile(empresas$idade, 0.5)
Q3 = quantile(empresas$idade, 0.75)
print(c(Q1, Q2, Q3))
```

```
##    25%    50%    75%
##  8.00 15.00 22.75
```



Medidas de dispersão

Amplitude total

- ▶ Diferença entre valores mínimo e máximo nos dados

$$AT = X_{max} - X_{min}$$

- ▶ Para calcular amplitude total no R, basta usar as funções `max()` e `min()`

Amplitude total

- ▶ Diferença entre valores mínimo e máximo nos dados

$$AT = X_{max} - X_{min}$$

- ▶ Para calcular amplitude total no R, basta usar as funções `max()` e `min()`

Amplitude total do tempo de existência das empresas

```
max(empresas$idade) - min(empresas$idade)
```

```
## [1] 40
```


Variância e desvio padrão amostral

- Dado um conjunto de dados $x_1, \dots, x_n$, a variância é calculada como

$$\text{Var}(X) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2,$$

em que $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ é a média aritmética

Variância e desvio padrão amostral

- ▶ Dado um conjunto de dados $x_1, \dots, x_n$, a variância é calculada como

$$\text{Var}(X) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2,$$

em que $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ é a média aritmética

- ▶ O desvio padrão é simplesmente a raiz quadrada da variância:

$$\text{dp}(X) = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}.$$

- ▶ Em R, `var()` calcula variância e `sd()` calcula o desvio padrão de um vetor de dados

Variância do tempo de existência

```
var(empresas$idade)
```

```
## [1] 93.64142
```

- ▶ Em R, `var()` calcula variância e `sd()` calcula o desvio padrão de um vetor de dados

Variância do tempo de existência

```
var(empresas$idade)
```

```
## [1] 93.64142
```

Desvio padrão do tempo de existência

```
sd(empresas$idade)
```

```
## [1] 9.67685
```

Coeficiente de variação

- ▶ É definido como a razão do desvio padrão e da média

$$CV = \frac{dp(X)}{\bar{X}},$$

em que $\bar{X}$ é a média aritmética e $dp(X)$ é o desvio padrão

Coeficiente de variação

- ▶ É definido como a razão do desvio padrão e da média

$$CV = \frac{dp(X)}{\bar{X}},$$

em que $\bar{X}$ é a média aritmética e $dp(X)$ é o desvio padrão

- ▶ Em R, usamos as funções `mean()` e `sd()` para calcular o CV

Coeficiente de variação do tempo de existência

```
mean(empresas$idade)/sd(empresas$idade)
```


```
## [1] 1.605661
```

- ▶ Vamos comparar os faturamentos das empresas nos anos de 1998 e 1999
- ▶ O intuito é checar se houve um aumento nos faturamentos de 1999 em comparação aos faturamentos de 1998
- ▶ para agilizar a análise, vamos salvar esses dados em variáveis com nomes mais simples

```
f98 = empresas$faturamento98
```

```
f99 = empresas$faturamento99
```

```
hist(f98, ylim = c(0, 45), col='blue')  
hist(f99, col='magenta', density = 10, add = TRUE)  
legend('topright',title='Anos',legend=c('1998','1999'),  
      fill = c('blue', 'magenta'))
```



Medidas de posição central: faturamentos

Faturamento em 1998

```
summary(f98)
```

##	Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
##	64302	247827	323766	327221	400869	674067

Faturamento em 1999

```
summary(f99)
```

##	Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
##	74392	256231	327898	334265	397745	685430

Medidas de dispersão: faturamentos

Faturamento em 1998

```
sd(f98)
```

```
## [1] 110376.7
```

```
sd(f98)/mean(f98)
```

```
## [1] 0.3373159
```

Faturamento em 1999

```
sd(f99)
```

```
## [1] 105791.9
```


```
sd(f99)/mean(f99)
```

```
## [1] 0.3164911
```

Boxplot

- ▶ Gráfico que fornece diferentes informações sobre os conjunto de dados: posição central, dispersão, assimetria e outliers (observações discrepantes)
- ▶ Construído a partir dos quartis $Q1$, $Q2$ e $Q3$

Boxplot do tempo de existência das empresas



Boxplot para faturamentos em 1998 e 1999

```
boxplot(f98, f99,  
        names = c('1998', '1999'), ylab="Faturamento")
```





Gráfico de dispersão dos faturamentos em 1998 e 1999

```
plot(f98, f99,  
     xlab="Faturamento 1998", ylab="Faturamento 1999")
```



Coeficiente de correlação

- Dado um conjunto de dados $(x_1, y_1), \dots, (x_n, y_n)$, o coeficiente de correlação é calculado como

$$\text{cor}(X, Y) = \frac{1}{n} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{dp(X)} \right) \left(\frac{y_i - \bar{y}}{dp(Y)} \right),$$

em que $\bar{x}$ e $dp(X)$ são a média e desvio padrão de $x_1, \dots, x_n$, e $\bar{y}$ e $dp(Y)$ são a média e desvio padrão de $y_1, \dots, y_n$.

Coeficiente de correlação

- ▶ Dado um conjunto de dados $(x_1, y_1), \dots, (x_n, y_n)$, o coeficiente de correlação é calculado como

$$\text{cor}(X, Y) = \frac{1}{n} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{dp(X)} \right) \left(\frac{y_i - \bar{y}}{dp(Y)} \right),$$

em que $\bar{x}$ e $dp(X)$ são a média e desvio padrão de $x_1, \dots, x_n$, e $\bar{y}$ e $dp(Y)$ são a média e desvio padrão de $y_1, \dots, y_n$.

- ▶ Em R, `cor()` calcula o coeficiente de correlação de dois vetores de dados com tamanhos iguais

```
cor(f98, f99)
```

```
## [1] 0.8701772
```


Exercício

Dados de prefeitos

- ▶ Baixe a planilha no link '[Dados de prefeitos](#)' no Moodle
- ▶ Carregue esses dados no Google Colab e utilize o R para responder as seguintes perguntas:
 - ▶ Quantas pessoas de cada sexo foram prefeitos em 2021?
 - ▶ Qual foi o nível de escolaridade mais comum dentre os prefeitos?
 - ▶ Qual é a população média e mediana das cidades?
 - ▶ Como é a distribuição (histograma) das idades dos prefeitos?
 - ▶ Qual é a correlação entre a idade dos prefeitos e a população das cidades?